Université du Québec en Outaouais
Département d'informatique et d'ingénierie

Segmentation Automatique de Cellules

Préparé par :
Sabra El Hajjaji
Sarra Bali yasmine

Cours :
INF7093-01 Éléments avancés d'analyse d'images

Enseignant :
Nadia Baaziz, Ing. Ph.D. et Etienne St-Onge, Ph.D. et

Gatineau, 4 décembre 2025

Résumé

Ce projet porte sur la segmentation automatique de cellules à partir de l'image multicanale `cells3d` de la bibliothèque `scikit-image`. L'objectif est de détecter, isoler et analyser chaque cellule afin d'extraire des statistiques morphologiques et photométriques telles que l'aire en pixels et les intensités moyennes en R, G et B.

Dans un premier temps, un pipeline complet de prétraitement a été mis en place (convertissage en niveaux de gris, lissage gaussien, égalisation d'histogramme, seuillage d'Otsu et opérations morphologiques) permettant d'obtenir un masque binaire propre. Une segmentation avancée par l'algorithme *Watershed*, guidée par la transformée de distance et les maxima locaux, a ensuite été appliquée pour séparer les cellules même lorsqu'elles sont fortement collées.

L'analyse quantitative a permis d'identifier 21 cellules distinctes, d'en mesurer la taille et d'en caractériser la couleur dominante. Enfin, deux méthodes du cours (segmentation par régions et segmentation par *K-means*) ont été testées et comparées, montrant qu'elles ne permettent pas de séparer correctement les cellules adjacentes et confirment l'intérêt de la méthode *Watershed* pour ce type d'image biomédicale.

Ce travail illustre l'importance d'un prétraitement rigoureux et du choix d'une méthode de segmentation adaptée pour obtenir une analyse fiable des structures cellulaires.

Table des matières

1 Introduction **3**

2 Partie A : Prétraitement de l'image **4**
2.1 Analyse des canaux couleur 4
2.2 Pipeline complet de prétraitement 4

3 Partie B : Segmentation par Watershed **7**
3.1 Transformée de distance et principe de la méthode 7
3.2 Construction des marqueurs 7
3.3 Segmentation finale et contours sur l'image originale 8

4 Partie C : Analyse quantitative des cellules **10**
4.1 Caractéristiques des cellules 10
4.2 Distribution des tailles 10
4.3 Analyse photométrique 11

5 Partie D : Méthodes du cours testées et limites **13**
5.1 Segmentation par régions 13
5.2 Segmentation par K-means 14
5.3 Conclusion sur les méthodes testées 15

6 Conclusion **16**

1 Introduction

La segmentation automatique de cellules en microscopie est une étape essentielle pour de nombreuses tâches d'analyse biomédicale : comptage cellulaire, mesure de taille, caractérisation de l'état d'une cellule (cycle cellulaire, apoptose), ou encore suivi de l'évolution d'un traitement. L'objectif est d'isoler chaque cellule comme une région cohérente afin de pouvoir en extraire des mesures fiables (aire, intensité moyenne, etc.).

Dans ce projet, nous travaillons sur une image issue de la base `cells3d` de *scikit-image*, constituée de plusieurs canaux de fluorescence. À partir de cette image, l'énoncé du Sujet #1 demande de :

A) filtrer l'image couleur, extraire les structures pertinentes, et produire un masque exploitable pour la segmentation ;

B) implémenter un code Python permettant de détecter automatiquement les cellules, de les séparer les unes des autres et du fond, puis de produire une image de segmentation où chaque cellule est associée à une étiquette (couleur) ;

C) compter le nombre de cellules et calculer des statistiques morphologiques (taille en pixels) et photométriques (intensités moyennes en R, G, B).

Pour répondre à ces objectifs, nous avons conçu un pipeline complet en Python en utilisant principalement les bibliothèques `NumPy`, `SciPy` et `scikit-image`. Plusieurs approches de segmentation ont été testées :

— les méthodes dites « classiques » du cours (segmentation par régions et morphologie) ;

— une segmentation non supervisée par *K-means* sur les intensités ;

— une segmentation avancée par l'algorithme *Watershed* guidé par la transformée de distance.

Après comparaison, la méthode *Watershed* s'est révélée la plus adaptée pour séparer correctement les cellules collées et permettre une analyse quantitative fiable. Les autres approches sont néanmoins documentées afin de discuter leurs limites.

La suite du rapport est structurée comme suit. La Partie A décrit en détail le prétraitement de l'image et la construction du masque binaire. La Partie B présente l'algorithme de segmentation *Watershed* et la manière dont nous construisons les marqueurs à partir de la transformée de distance. La Partie C est consacrée à l'analyse quantitative des cellules segmentées. Enfin, la Partie D discute les méthodes issues du cours que nous avons testées (segmentation par régions et K-means) et explique pourquoi elles sont moins performantes dans ce contexte.

2 Partie A : Prétraitement de l'image

L'objectif du prétraitement est de transformer l'image couleur de départ en un masque binaire propre, sur lequel il sera possible d'appliquer une segmentation robuste. Un bon prétraitement doit à la fois réduire le bruit, mettre en évidence les structures pertinentes (ici les cellules) et éliminer autant que possible les artefacts.

2.1 Analyse des canaux couleur

L'image `cells3d` est composée de plusieurs canaux de fluorescence que nous recombinerons en une image RGB à l'aide de la commande :

```
from skimage.data import cells3d as c3d
cell_img = np.stack((c3d()[20,1],
                     c3d()[36,1]/2,
                     c3d()[30,0]),
                    axis=2)
```

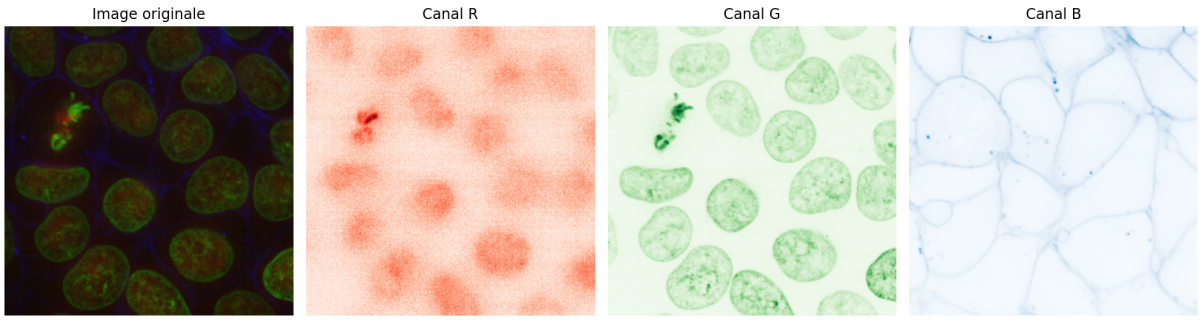

FIGURE 1 – Image originale et décomposition en canaux R, G et B. Le canal vert met en évidence la structure des cellules.

La (Figure 1). illustre l'image RGB ainsi que chacun des canaux R, G et B visualisés séparément. On observe que :

- le canal rouge met en évidence certaines structures internes mais avec un contraste relativement faible ;
- le canal bleu est peu informatif pour les contours cellulaires (signal plus faible, structures moins nettes) ;
- le canal vert met clairement en évidence les membranes et les noyaux, avec un contraste marqué entre les cellules et le fond.

Le canal vert apparaît ainsi comme le plus informatif pour la segmentation. Cela justifie la conversion de l'image RGB en niveaux de gris, dominée par la contribution du canal G, avant les étapes de filtrage et de seuillage.

2.2 Pipeline complet de prétraitement

La Figure 2 présente le pipeline complet de prétraitement, depuis l'image brute jusqu'au masque binaire final. Ce pipeline est composé des étapes suivantes :

Conversion en niveaux de gris. Après l'analyse des canaux couleur, nous avons observé que le canal vert contenait la majorité de l'information structurelle utile pour la segmentation. Afin de simplifier l'image et de travailler sur une intensité unique, nous avons appliqué une conversion en niveaux de gris à l'aide de la fonction `rgb2gray`. L'image obtenu represente une base cohérente pour les étapes ultérieures du prétraitement.

Essais des filtres de lissage : Nous avons choisi le filtre gaussien pour réduire le bruit présent dans l'image. Avant d'adopter un sigma de 1.5, plusieurs valeurs ont été testées :

- $\sigma = 0.5$: bruit encore trop présent ;
- $\sigma = 1.0$: compromis acceptable, mais contours légèrement irréguliers ;
- $\sigma = 1.5$: réduction efficace du bruit tout en conservant les structures cellulaires ;
- $\sigma = 2.0$: sur-lissage, perte de détails et début de fusion entre certaines cellules.

Ces essais justifient pleinement le choix de $\sigma = 1.5$, qui maximise la stabilité du seuillage et de la transformée de distance.

Amélioration de contraste : Nous appliquons ensuite une égalisation d'histogramme (`exposure.equalize_hist`) afin d'étaler les intensités et d'augmenter le contraste entre les cellules et le fond. Cette étape stabilise le seuillage global en rendant la séparation fond/objet plus nette.

Extraction du gradient (Sobel) : Pour visualiser la structure des contours, nous calculons le gradient de l'image lissée à l'aide de l'opérateur de Sobel. Celui-ci agit comme un filtre dérivatif discret et produit une forte réponse aux bords. Plusieurs opérateurs (*Prewitt*, *Sobel*, *Scharr*) ont été envisagés ; *Sobel* offre un bon compromis entre robustesse au bruit et précision des bords, et a donc été retenu.

Tests des méthodes de seuillage : Nous avons testé plusieurs approches de seuillage pour séparer automatiquement les cellules du fond : un seuillage local (adaptatif) et un seuillage global. Le seuillage local, basé sur un seuil variable calculé dans de petites régions de l'image. Ce type de seuillage a produit des régions irrégulières. Cependant, le seuillage globale d'Otsu a donné des résultats plus efficace et plus cohérents. Pour cette raison, on a choisi le seuillage d'Otsu comme méthode finale.

Remplissage des trous : Nous avons decidé d'appliquer un remplissage des trous (`binary_fill_holes`) afin d'obtenir des régions pleines et uniformes. Cette opération garantit que chaque cellule soit représentée comme un objet connecté, ce qui est indispensable pour la transformée de distance et la segmentation Watershed.

Choix de la structuration morphologique : Les opérations morphologiques jouent un rôle très important dans la stabilisation du masque binaire. Nous avons testé plusieurs éléments structurants pour les opérations de fermeture et d'ouverture :

- disque de rayon 2 : suppression trop faible du bruit ;
- disque de rayon 3 : bon équilibre, mais contours légèrement altérés ;
- structurant carré : non adapté à la forme arrondie des cellules ;
- matrice personnalisée (5×5) : meilleurs résultats observés.

Nous avons appliqué une fermeture, puis une ouverture. Ce choix est intentionnel : la **fermeture** permet de combler les petits trous à l'intérieur des cellules, ce qui est essentiel pour éviter leur fragmentation lors de la segmentation. Ensuite, l'**ouverture** élimine les petits objets isolés et le bruit autour des cellules, tout en préservant leur forme réelle. La structure circulaire 5×5 a été retenue, car elle offre des résultats de fermeture et d'ouverture plus robustes tout en respectant la morphologie arrondie des cellules.

Suppression des petits objets. Enfin, nous utilisons la fonction `remove_small_objects` avec un seuil de 50 pixels pour supprimer les artefacts de très petite taille. Cette valeur a été déterminée empiriquement : elle supprime efficacement le bruit sans éliminer de véritables cellules. Le masque binaire final (Figure 2, dernière image) constitue l'entrée de l'algorithme *Watershed* présenté dans la Partie B.

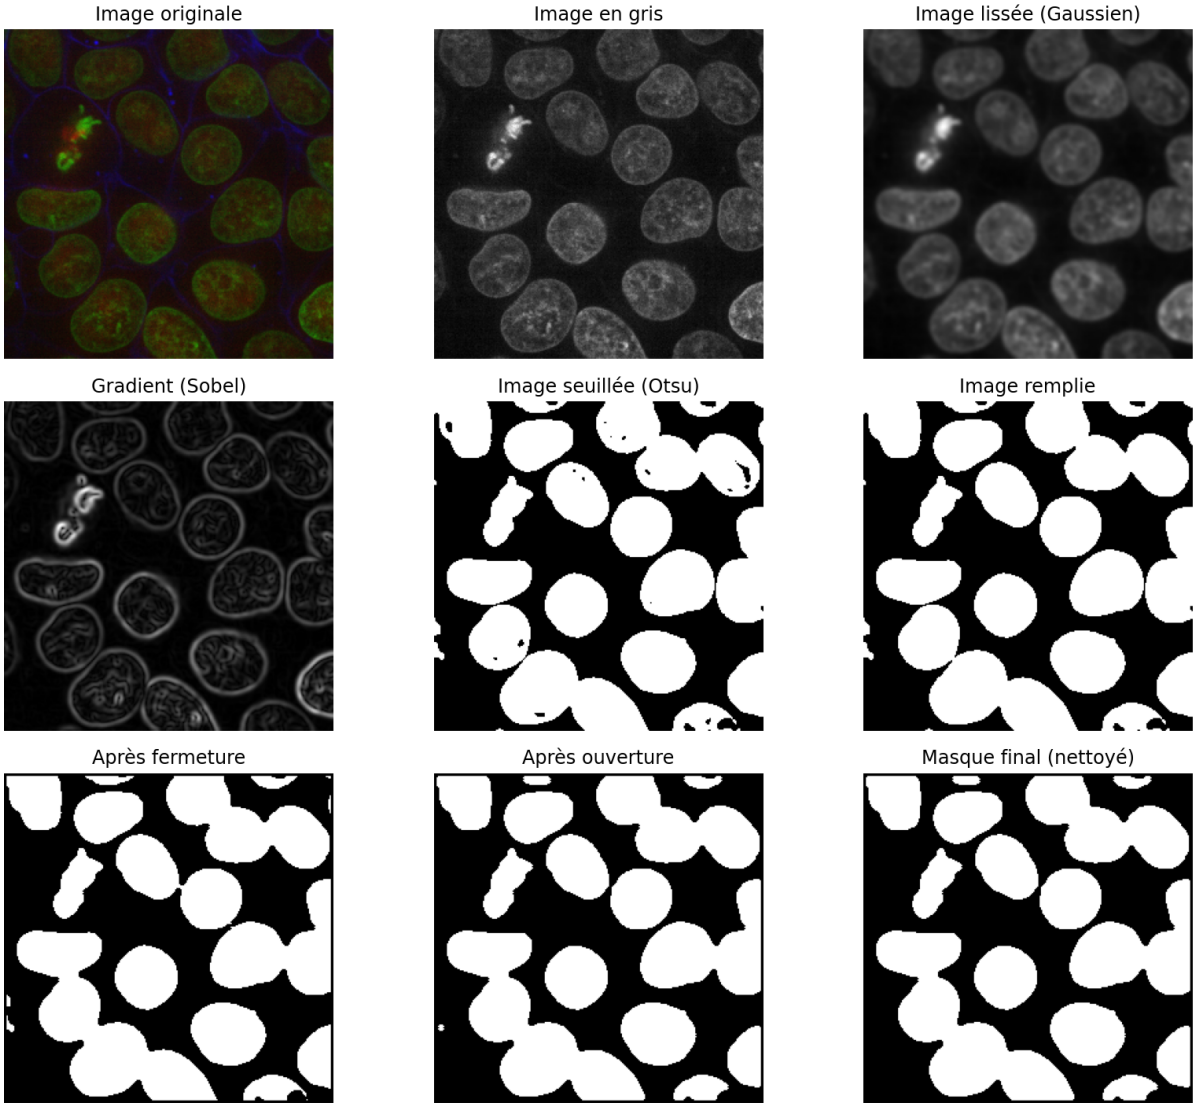

FIGURE 2 – Pipeline complet de prétraitement : du bruit initial vers un masque propre et exploitable.

3 Partie B : Segmentation par Watershed

Une fois le masque binaire construit, il reste à séparer les cellules entre elles, notamment lorsqu'elles sont fortement collées. Pour cela, nous utilisons l'algorithme *Watershed* implémenté dans `scikit-image`, en nous basant sur la transformée de distance euclidienne.

3.1 Transformée de distance et principe de la méthode

La transformée de distance associe à chaque pixel de l'objet (ici, les cellules) sa distance minimale au fond. Dans notre cas, cette transformée est calculée sur le masque binaire `mask_cells` à l'aide de la fonction `ndi.distance_transform_edt`. Le résultat peut être interprété comme une surface topographique où :

— le centre de chaque cellule correspond à un « sommet » (distance maximale au fond) ;

— les zones proches des frontières ont une distance plus faible.

La Figure 3 illustre le masque binaire, la transformée de distance lissée et la segmentation finale obtenue.

Plus la distance est grande, plus nous sommes au « centre » de la cellule. En inversant cette carte de distance, la méthode *Watershed* va « inonder » le relief à partir de points de départ (les marqueurs) jusqu'à rencontrer une crête, ce qui délimite naturellement les frontières entre cellules.

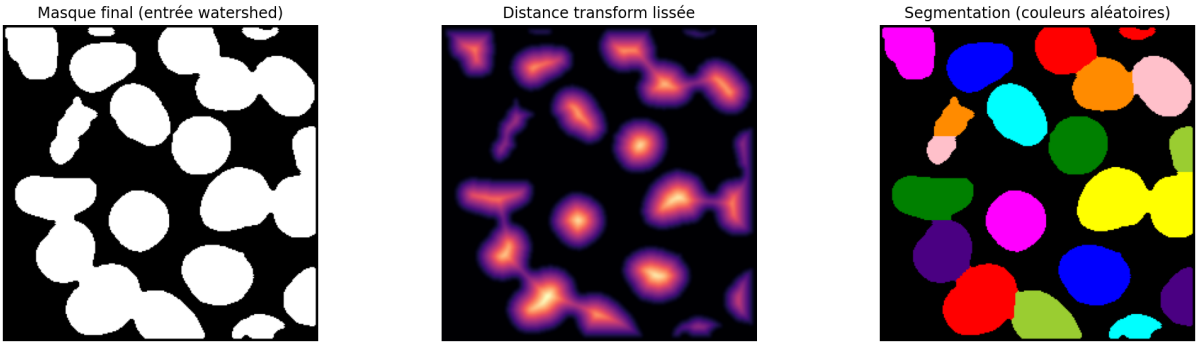

FIGURE 3 – Masque final, transformée de distance lissée et segmentation Watershed.

3.2 Construction des marqueurs

Pour guider correctement *Watershed*, il est indispensable de disposer d'un marqueur par cellule. Nous détectons donc les maxima locaux de la transformée de distance lissée (`distance_smooth`) à l'aide de la fonction `peak_local_max` :

```
coords = peak_local_max(distance_smooth,
                        labels=mask_cells,
                        min_distance=15)
```

Le paramètre `min_distance` impose une distance minimale entre deux maxima successifs et permet d'éviter une sur-segmentation où une même cellule serait découpée en plusieurs régions. Plusieurs valeurs ont été testées :

— `min_distance` trop petit (< 10) : apparition de multiple maxima à l'intérieur d'une même cellule, conduisant à des découpes non souhaitées ;
— `min_distance` trop grand (> 20) : certaines cellules collées ne reçoivent qu'un seul marqueur et restent fusionnées ;
— `min_distance` $= 15$: bon compromis, chaque cellule obtient en général un marqueur unique.

À partir des coordonnées trouvées, nous construisons une image de marqueurs où chaque maximum est associée à une étiquette entière. La Figure 4 montre la transformée de distance avec les maxima locaux superposés.

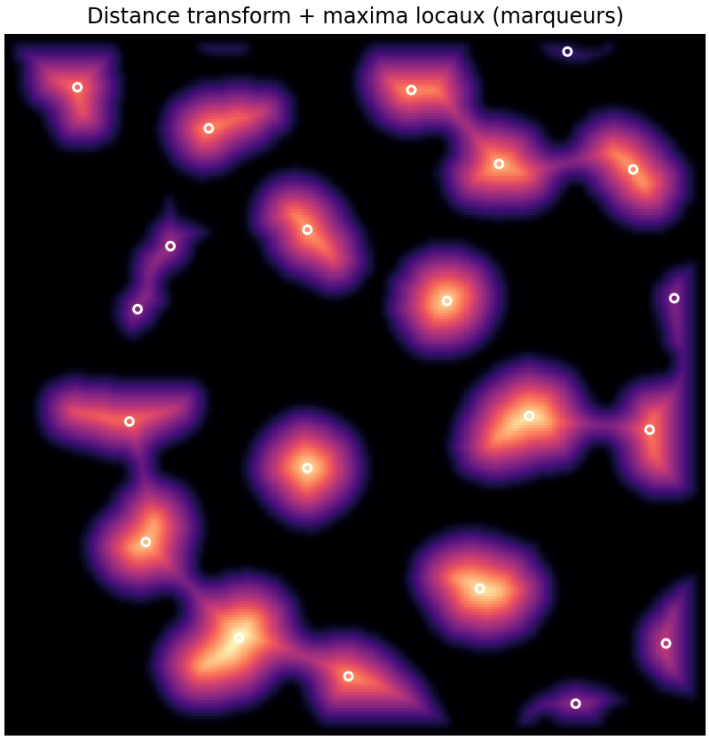

FIGURE 4 – Maxima locaux utilisés comme marqueurs pour Watershed.

3.3 Segmentation finale et contours sur l'image originale

L'appel à *Watershed* se fait ensuite par :

```
labels_ws = watershed(-distance_smooth,
                      markers,
                      mask=mask_cells)
```

L'image `labels_ws` contient une étiquette entière pour chaque cellule. Pour visualiser le résultat, nous générons une image en fausses couleurs à l'aide de `label2rgb` (Figure 3, troisième image). Enfin, nous projetons les frontières de segmentation sur l'image couleur originale avec la fonction `mark_boundaries`. La Figure 5 montre que les contours suivent bien les membranes cellulaires, y compris dans les zones où plusieurs cellules sont collées.

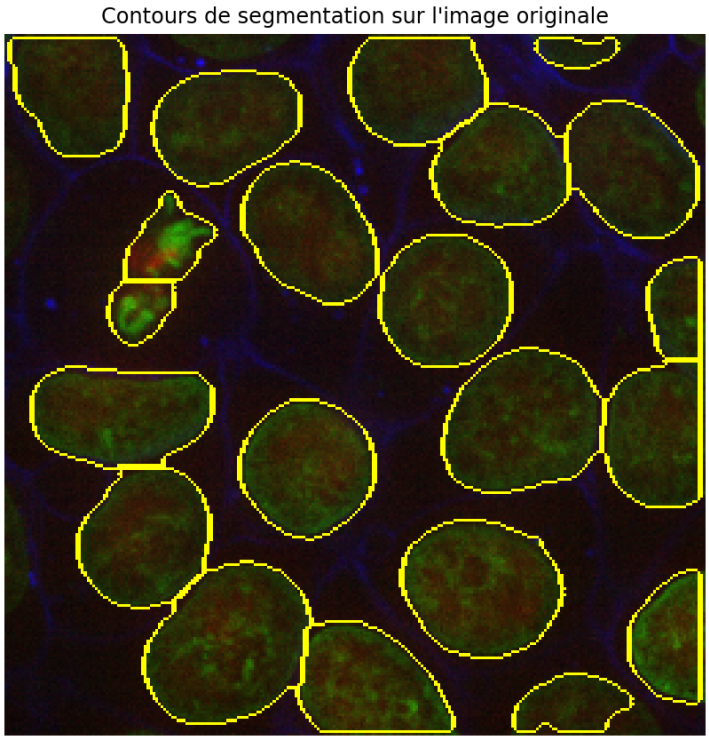

FIGURE 5 – Contours de Watershed superposés à l'image originale.

Cette étape valide la qualité de la segmentation : chaque cellule visible à l'œil nu est associée à une région distincte, ce qui permet de réaliser une analyse quantitative fiable dans la Partie C.

4 Partie C : Analyse quantitative des cellules

Après la segmentation par *Watershed*, chaque cellule est identifiée par une étiquette entière dans l'image `labels_ws`. Nous pouvons alors calculer, pour chaque cellule :

— son aire en nombre de pixels ;
— ses intensités moyennes dans les canaux R, G et B ;
— une couleur dominante (rouge, verte ou bleue).

4.1 Caractéristiques des cellules

Le nombre total de cellules détectées est de **21**. Pour l'étiquette i, nous construisons un masque booléen `labels_ws == i`, à partir duquel nous extrayons les valeurs des canaux R, G et B, puis calculons les moyennes :

$$\overline{R}_i = \frac{1}{N_i} \sum_{p \in \text{cellule } i} R(p), \quad \overline{G}_i = \frac{1}{N_i} \sum_{p \in \text{cellule } i} G(p), \quad \overline{B}_i = \frac{1}{N_i} \sum_{p \in \text{cellule } i} B(p),$$

où N_i est le nombre de pixels de la cellule i.

La couleur dominante est ensuite définie comme le canal ayant la plus grande moyenne. Le tableau 1 présente un extrait de ces résultats.

Table 1 – Caractéristiques des cellules segmentées (extrait).

Cellule	Aire (px)	R_{mean}	G_{mean}	B_{mean}	Couleur dom.
1	2656	0.1649	0.1585	0.0248	Plus rouge
2	2222	0.1865	0.1741	0.0243	Plus rouge
3	2355	0.1533	0.1608	0.0341	Plus verte
4	1853	0.1771	0.1854	0.0367	Plus verte
5	1820	0.1596	0.1590	0.0411	Plus rouge
…(21 cellules au total) …					

4.2 Distribution des tailles

La Figure 6 montre l'histogramme des aires des cellules (en pixels). La majorité des cellules se situe dans une plage relativement homogène, typiquement entre 1500 et 2500 pixels. Quelques cellules légèrement plus grandes peuvent correspondre à des cellules en division ou à des cellules partiellement fusionnées sur l'image d'origine, tandis que les plus petites aires correspondent souvent à des cellules en bord d'image ou partiellement tronquées.

Cette distribution relativement resserrée indique que la segmentation ne produit pas de grosses erreurs (pas de « méga-cellules » anormalement grandes), ce qui confirme que *Watershed* sépare efficacement les cellules collées.

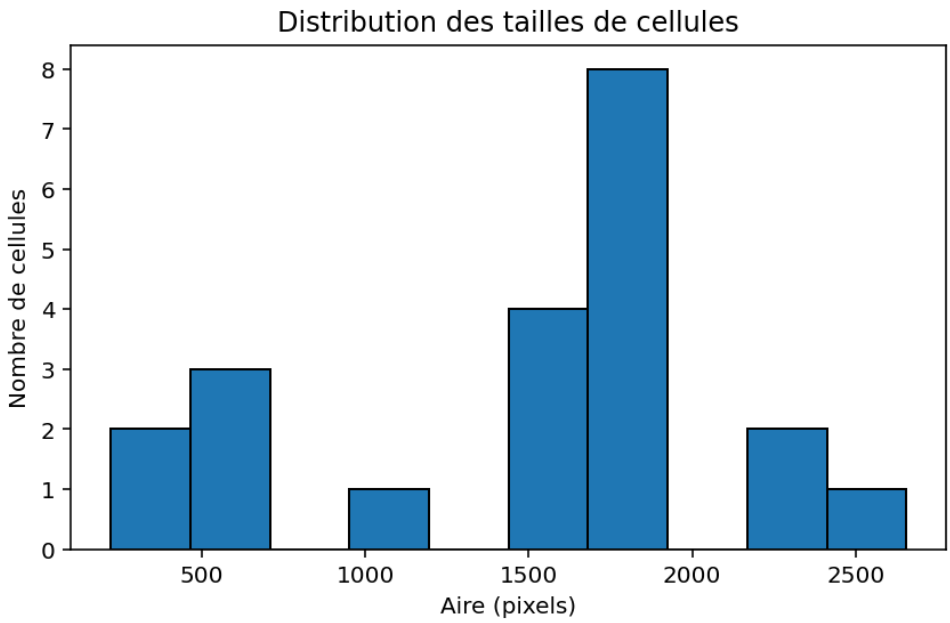

FIGURE 6 – Distribution des aires segmentées.

4.3 Analyse photométrique

La Figure 7 présente un nuage de points $(R_{\text{mean}}, G_{\text{mean}})$ pour chaque cellule, avec un code couleur indiquant la couleur dominante. On observe que la plupart des cellules se regroupent dans une zone où R_{mean} et G_{mean} sont relativement proches, avec un léger avantage pour le canal vert.

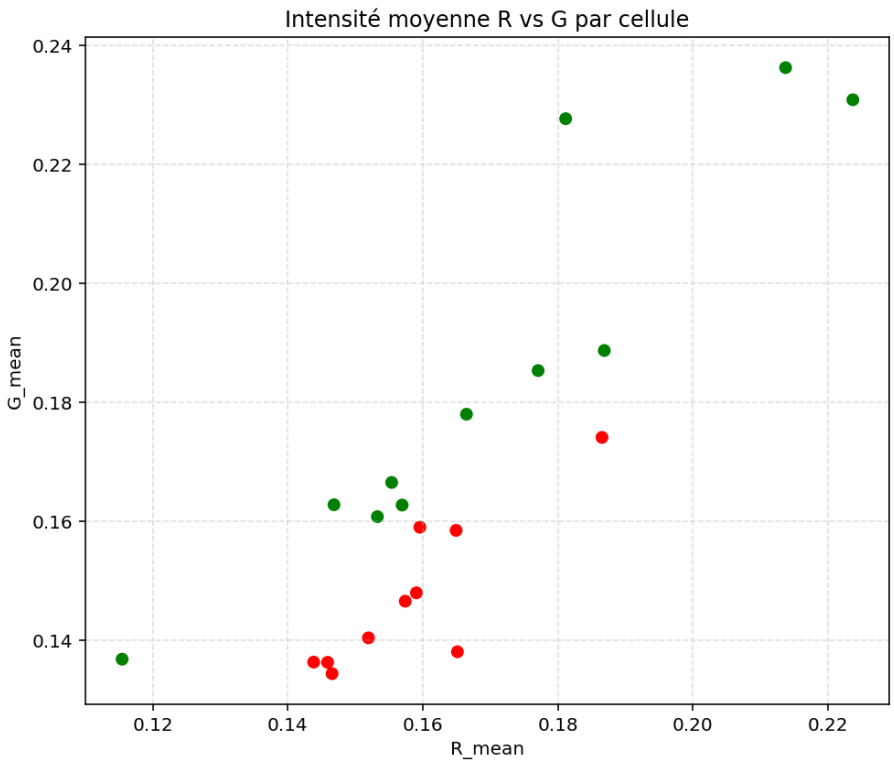

FIGURE 7 – Nuage R_mean vs G_mean avec codage couleur.

La Figure 8 résume cette observation en comptant le nombre de cellules principalement « plus vertes » ou « plus rouges ». Globalement, les cellules sont légèrement plus vertes que rouges, ce qui est cohérent avec le fait que le canal vert met en évidence la structure cytoplasmique dans cette acquisition de fluorescence.

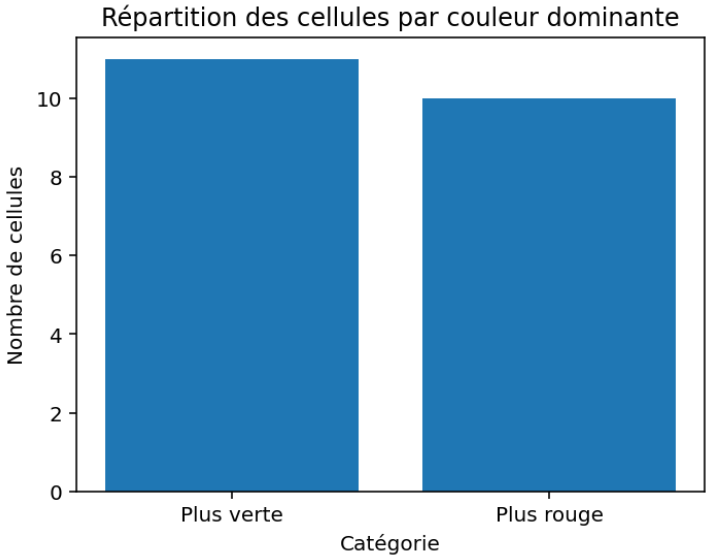

FIGURE 8 – Répartition des cellules par couleur dominante.

Ces mesures photométriques, combinées à l'aire, constituent une base pour des analyses plus avancées (détection de cellules atypiques, suivi de traitement, etc.).

5 Partie D : Méthodes du cours testées et limites

En complément de la méthode *Watershed*, nous avons évalué deux approches issues du cours : la segmentation par régions et la segmentation non supervisée par *K-means*. Les résultats montrent que, bien qu'elles soient simples à mettre en œuvre, ces méthodes ne permettent pas d'obtenir une séparation correcte des cellules.

5.1 Segmentation par régions

La segmentation par régions consiste à appliquer un seuillage puis à extraire les composantes connectées du masque binaire. La Figure 9 montre le masque obtenu après les opérations morphologiques, ainsi que la segmentation finale en composantes connectées.

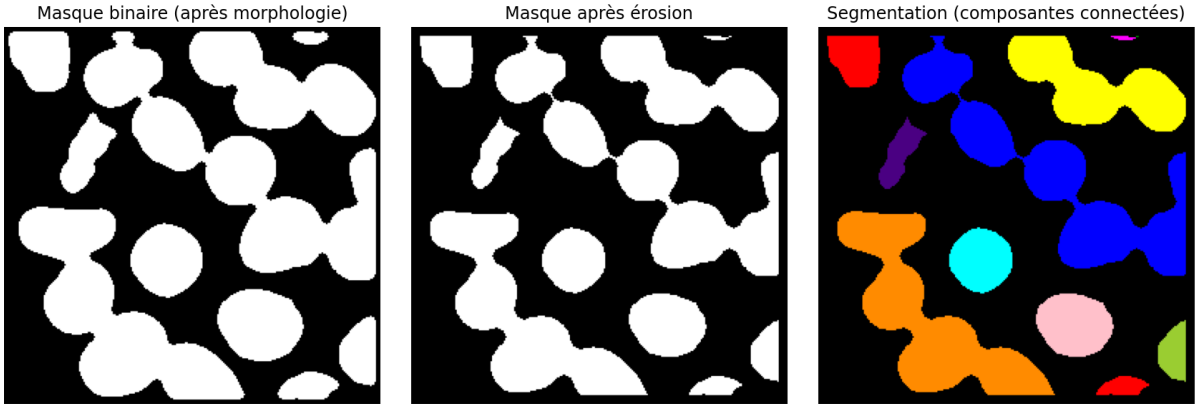

FIGURE 9 – Segmentation par régions : (gauche) masque binaire après morphologie, (centre) masque après érosion, (droite) segmentation en composantes connectées. Plusieurs cellules fusionnent en un seul objet, ce qui empêche un comptage fiable.

La projection des contours sur l'image originale (Figure 10) montre que de nombreuses cellules adjacentes sont fusionnées. La méthode ne parvient pas à séparer les cellules en contact, ce qui entraîne une sous-segmentation majeure.

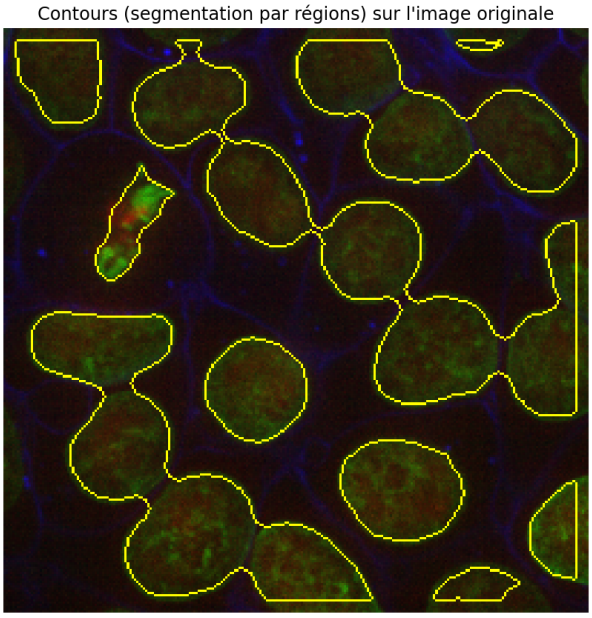

FIGURE 10 – Contours de la segmentation par régions superposés à l'image originale. Les cellules collées sont systématiquement fusionnées.

5.2 Segmentation par K-means

Nous avons ensuite testé une segmentation non supervisée par *K-means* appliquée à l'image en niveaux de gris. La Figure 11 présente le masque brut produit par le cluster principal, le masque nettoyé, ainsi que la segmentation par composantes connectées appliquée à ce masque.

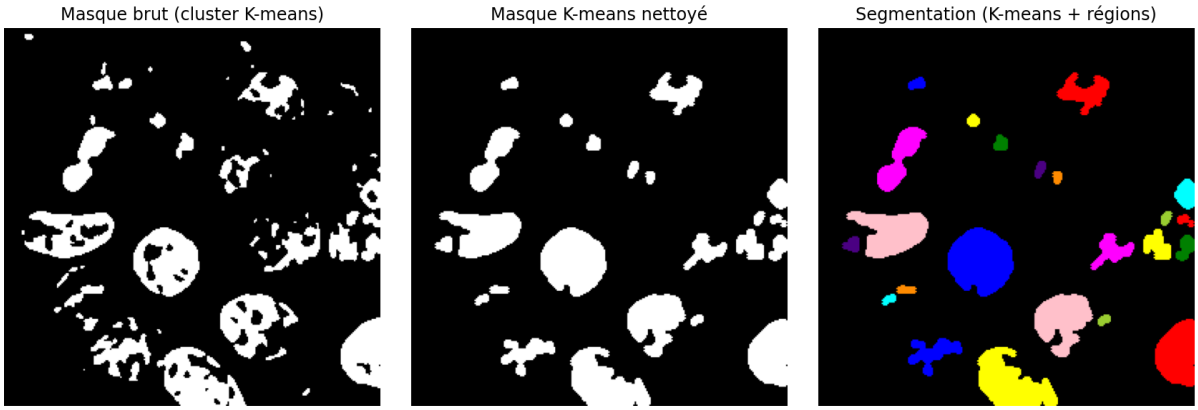

FIGURE 11 – Segmentation par K-means : (gauche) masque brut du cluster, (centre) masque nettoyé, (droite) segmentation obtenue. La méthode ne respecte pas les contours cellulaires et segmente principalement la texture plutôt que les objets biologiques.

La Figure 12 montre les contours K-means superposés à l'image originale. Les frontières obtenues ne suivent pas les membranes cellulaires, et les cellules collées ne sont jamais séparées.

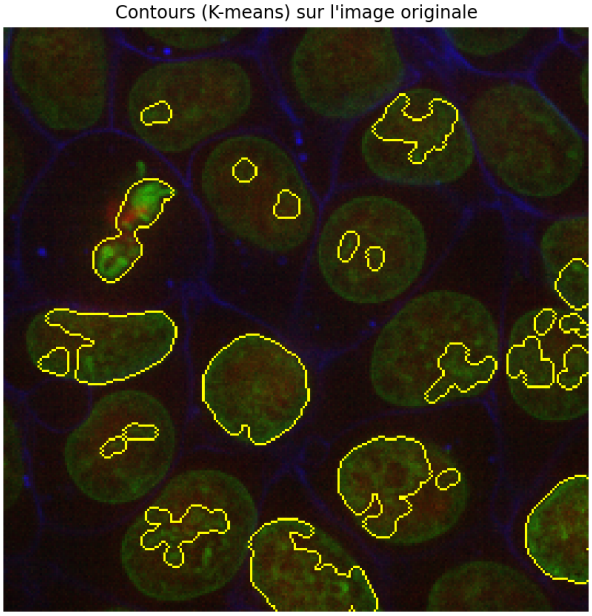

FIGURE 12 – Contours obtenus par K-means projetés sur l'image originale. Les contours sont imprécis et ne suivent pas la morphologie réelle des cellules.

5.3 Conclusion sur les méthodes testées

Les deux méthodes présentent des limitations majeures :

— la segmentation par régions fusionne systématiquement les cellules collées ;

— K-means segmente la texture plutôt que la forme, et ne respecte pas les contours cellulaires ;

— aucune des deux méthodes ne permet un comptage correct ou une analyse morphologique fiable.

Ces résultats justifient pleinement le recours à la méthode *Watershed*, qui exploite la transformée de distance pour séparer efficacement les cellules adjacentes.

6 Conclusion

Ce projet a permis de développer une chaîne complète et efficace de traitement d'images pour la segmentation automatique de cellules à partir de l'image multicanale `cells3d`. Dans la Partie A, un prétraitement rigoureux — comprenant filtrage, ajustement du contraste, seuillage d'Otsu et opérations morphologiques — a permis d'obtenir un masque binaire propre et adapté à la segmentation.

Dans la Partie B, l'algorithme *Watershed*, guidé par la transformée de distance et les maxima locaux, s'est révélé particulièrement efficace pour séparer les cellules collées. L'utilisation de marqueurs bien définis a permis d'obtenir une segmentation cohérente, fidèle aux contours cellulaires visibles sur l'image originale.

La Partie C a montré que cette segmentation permettait une analyse quantitative fiable : comptage du nombre total de cellules, calcul de leur aire en pixels et extraction des intensités moyennes dans les canaux R, G et B afin de déterminer la couleur dominante. Ces mesures constituent une base solide pour des applications biomédicales telles que l'étude de populations cellulaires ou l'évaluation de conditions expérimentales.

Perspectives et améliorations futures

Bien que les résultats obtenus soient satisfaisants, plusieurs améliorations peuvent être envisagées :

- **Extension à la 3D** : appliquer la segmentation à l'ensemble du volume `cells3d` plutôt qu'à une seule coupe, permettant une analyse volumétrique des cellules.
- **Affinement des marqueurs Watershed** : utiliser des techniques supplémentaires (gradient, Laplacien, seeds basés sur la morphologie) pour éviter les rares cas de sous- ou sur-segmentation.
- **Modèles d'apprentissage profond** : comparer les résultats avec des architectures modernes comme U-Net, largement utilisées pour la segmentation biomédicale et souvent plus robustes au bruit et aux variations d'illumination.
- **Analyse statistique avancée** : exploiter les mesures extraites (aire, intensité, couleur dominante) pour classifier les cellules ou détecter des anomalies morphologiques.

Ces pistes offrent un potentiel d'amélioration significatif et pourraient enrichir l'analyse cellulaire dans des contextes plus complexes ou sur des jeux de données plus variés.

Références

[1] Étienne St-Onge et Nadia Baaziz, *INF7093 — Éléments avancés d'analyse d'images*, Université du Québec en Outaouais, Notes de cours, 2025.

[2] R. C. Gonzalez et R. E. Woods, *Digital Image Processing*, 4e édition, Pearson, 2018.

[3] Serrano, M., *Watershed Algorithm Explained*, YouTube, 2020. Disponible : `https://www.youtube.com/watch?v=FLmxZaQhvsI`

[4] Van der Walt, S. et al., *scikit-image : image processing in Python*, PeerJ 2 :e453, 2014. Documentation officielle : `https://scikit-image.org`

[5] Harris, C. R. et al., *Array programming with NumPy*, Nature, 585, 357–362 (2020).

[6] Virtanen, P. et al., *SciPy 1.0 : fundamental algorithms for scientific computing in Python*, Nature Methods 17, 261–272 (2020).

[7] Beucher, S. et Meyer, F., *The Morphological Approach to Segmentation : The Watershed Transformation*, Mathematical Morphology in Image Processing, 1993.

[8] N. Otsu, *A Threshold Selection Method from Gray-Level Histograms*, IEEE Transactions on Systems, Man, and Cybernetics, 1979.

[9] Skimage Documentation — `peak_local_max`, Disponible : `https://scikit-image.org/docs/stable/auto_examples/segmentation/plot_watershed.html`